

Projet de programmation encadré - LYSET13

Vue d'ensemble

Pierre Magistry pierre.magistry@inalco.fr

Yoann Dupont yoann.dupont@sorbonne-nouvelle.fr

2026–2027

Université Sorbonne-Nouvelle
INALCO
Université Paris-Nanterre

Généralités

Se référer au syllabus du cours

- Les horaires et lieux
 - 9h - 12h, campus Nation, salle B326
 - github: <https://github.com/YoannDupont/PPE1-2627>
 - iCampus (P3) :
<https://icampus.univ-paris3.fr/course/view.php?id=82362>
 - clé d'autoinscription icampus : **PPE1@2627**

Se référer au syllabus du cours

- Les horaires et lieux
 - 9h - 12h, campus Nation, salle B326
 - github: <https://github.com/YoannDupont/PPE1-2627>
 - iCampus (P3) :
<https://icampus.univ-paris3.fr/course/view.php?id=82362>
 - clé d'autoinscription icampus : **PPE1@2627**
- Modalités de contrôle de connaissance (MCC)
 - **40%** - travail individuel
 - Exercices
 - Journal de bord individuel

Se référer au syllabus du cours

- Les horaires et lieux
 - 9h - 12h, campus Nation, salle B326
 - github: <https://github.com/YoannDupont/PPE1-2627>
 - iCampus (P3) :
<https://icampus.univ-paris3.fr/course/view.php?id=82362>
 - clé d'autoinscription icampus : **PPE1@2627**
- Modalités de contrôle de connaissance (MCC)
 - **40%** - travail individuel
 - Exercices
 - Journal de bord individuel
 - **60%** - projet en groupe (idéalement 3 personnes) → pensez-y tout de suite !
 - Une de suivi de projet
 - Une sur le résultat final

- Systèmes d'exploitation (OS) attendus : (K)Ubuntu dernière version (LTS), Debian dernière version stable ou MacOS

- Systèmes d'exploitation (OS) attendus : (K)Ubuntu dernière version (LTS), Debian dernière version stable ou MacOS
 - idéalement : votre seul OS
 - acceptable : *dual-boot* (deux systèmes cohabitent sur l'ordinateur)
 - bon courage : machine virtuelle, chromeOS, tout le reste en fait.

- Systèmes d'exploitation (OS) attendus : (K)Ubuntu dernière version (LTS), Debian dernière version stable ou MacOS
 - idéalement : votre seul OS
 - acceptable : *dual-boot* (deux systèmes cohabitent sur l'ordinateur)
 - bon courage : machine virtuelle, chromeOS, tout le reste en fait.
- Si vous n'entrez pas dans ces cases ou que vous avez des problèmes spécifiques, venez nous voir !

Vision globale du cours

Projet encadré ?


- Projet : *La vie des mots sur le web*
- projet initiatique à la linguistique de corpus et à Unix
 - projet à 3 (une personne de chaque université¹)
 - étudier l'usage un mot et ses "variations" en plusieurs langues sur le web
 - constituer un corpus multilingue → ensemble de textes compilés
 - constitution à l'aide d'outils Unix → occasion d'apprendre les outils avec une utilisation concrète de récolte des données textuelles et leur nettoyage²

Encadré car nous allons vous guider dans les premières étapes et ensuite suivre votre progression.

¹Seule exception : avarie de représentant(e)s


²Complément : *pure bash bible* <https://github.com/dylananaraps/pure-bash-bible>

Projet en deux phases



Crédit image ampoule : OpenClipart-Vectors (pixabay.com)

Projet en deux phases



Crédit image ampoule : OpenClipart-Vectors (pixabay.com)

Un mot (et ses « variations » dans les langues choisies)
+ 1 hypothèse (?)

Phase 1 : construction du corpus
Une chaîne de traitements informatiques

Quel type de données ?
Homogénéité des données ?

Un corpus multilingue

Phase 2 : exploration du corpus

Sémantique lexicale
Approche textométrique


Outils « maison » :
iTrameur / le Trameur

Analyse

- Programmer : « Fournir des instructions à la machine pour qu'elle réalise une tâche. »
 - « Écrire une liste ordonnée d'instructions processeur qui retranscrit l'algorithme permettant la réalisation de la tâche. »
 - Cette liste ordonnée d'instructions s'appelle un programme.
- Comment écrit-on ce programme ?
 - Grâce à un langage de programmation

- La partie « informatique » du projet consiste à :
 - Écrire une chaîne de traitement (des programmes) permettant
 - de récupérer des pages web (sélection par choix linguistique)
 - les traiter (détails donnés infra)
 - présenter les traitements dans une page web (des tableaux)
- Description infra du projet via graphiques
- Description du projet en pseudo code
 - Les différentes étapes à mettre en œuvre
 - Et à traduire en « vrai » code...

Exemple de projet passé



Le projet : ça n'est que quelques ligne de code finalement

Étant donné un fichier d'URL (le programme pourra traiter plusieurs fichiers d'URLS...)

- Pour chaque URL $\Leftarrow$ Boucle : for
 - Récupérer la page $\Leftarrow$ Commandes : curl, wget
 - la stocker localement dans le dossier idoine
 - Si pas d'erreur lors de la récupération $\Leftarrow$ Condition : if
 - Alors
 - Si la page est en UTF-8
 - Alors
 - En extraire le texte $\Leftarrow$ Commande : lynx
 - En extraire des contextes autour des mots choisis $\Leftarrow$ Commande : egrep
 - Sinon $\Leftarrow$ Alternative à if : else
 - On essaie de détecter l'encodage de la page $\Leftarrow$ Commande : file
 - Si l'encodage est reconnu
 - Alors
 - Extraire le texte $\Leftarrow$ Commande : iconv
 - Conversion en UTF-8
 - En extraire des contextes autour des mots choisis
 - Sinon
 - On ne fait rien
 - Sinon
 - On ne fait rien
 - Une URL traitée = création dans un tableau HTML d'une ligne où on stocke les éléments créés :
 - Liens vers page, page avec contenu textuel (utf-8 et encodage initial), contexte autour du pôle

Tableau n° 1						
FICHIER : LIENS.TXT						
n°URL	URL	PAGES ASPIREES	DUMP initial (non utf-8)	DUMP utf-8 MOTIF : LE	CONTEXTES utf-8 MOTIF : LE	CONTEXTES HTML MOTIF : LE
1	http://www.madore.org/~david/weblog/	1.html	-	1-utf8.txt	1-utf8.txt	1-utf8.html
2	http://tal.univ-paris3.fr/plurital/	2.html	2.txt (iso-8859-1)	2-utf8.txt	2-utf8.txt	2-utf8.html
3	http://tal.univ-paris3.fr/trameur/	3.html	3.txt (ISO-8859-1)	3-utf8.txt	3-utf8.txt	3-utf8.html
4	http://house.focus.cn/news/2007-02-26/285249.html	4.html	Encodage non détecté	Encodage non détecté	Encodage non détecté	Encodage non détecté
5	http://www.adab.com/modules.php?name=Sh3er&doWhat=shqas&qid=6124	5.html	5.txt (windows-1256)	5-utf8.txt	5-utf8.txt	5-utf8.html
				Fichier DUMP global 4 fichier(s)	Fichier CONTEXTES global 4 fichier(s)	

Tableau n° 2						
FICHIER : LIENS2.TXT						
n°URL	URL	PAGES ASPIREES	DUMP initial (non utf-8)	DUMP utf-8 MOTIF : LE	CONTEXTES utf-8 MOTIF : LE	CONTEXTES HTML MOTIF : LE
1	http://www.madore.org/~david/weblog/	1.html	-	1-utf8.txt	1-utf8.txt	1-utf8.html
2	http://tal.univ-paris3.fr/plurital/	2.html	2.txt (iso-8859-1)	2-utf8.txt	2-utf8.txt	2-utf8.html
3	http://tal.univ-paris3.fr/trameur/	3.html	3.txt (ISO-8859-1)	3-utf8.txt	3-utf8.txt	3-utf8.html
				Fichier DUMP global 3 fichier(s)	Fichier CONTEXTES global 3 fichier(s)	

Exemple (un peu ancien) de tableau à fournir.

Comment on va faire ?

Les "couches" d'un ordinateur





Figure 1: Source : <https://cdn.mindmajix.com>

Figure 2: Source : <https://cdn.mindmajix.com>

Les pipelines Unix



source : "Unix Pipeline (Brian Kernighan) - Computerphile" (Youtube)

Gestion de projet avec GitHub - le dépôt de vos fichiers

 **steeve** / **france.code-civil** Public

 Notifications  Fork 149  Star 2.7k

[Code](#) [Issues](#) 21 [Pull requests](#) 9 [Actions](#) [Projects](#) [Wiki](#) [Security](#) [Insights](#)

 master  3 branches  0 tags Go to file Code

 **steeve** Merge pull request #18 from Kcchouette/patch-1 ...  2 159d951 on 31 Mar 2015  281 commits

 Livre II	Modifié par LOI n°2015-177 du 16 février 2015 - art. 1 (V)	8 years ago
 Livre III	Modifié par LOI n°2015-177 du 16 février 2015 - art. 1 (V)	8 years ago
 Livre IV	Modifié par Ordonnance n°2014-326 du 12 mars 2014 - art. 100	8 years ago
 Livre Ier	Modifié par LOI n°2013-403 du 17 mai 2013 - art. 1 (V)	8 years ago
 Livre V	Modifié par LOI n°2015-177 du 16 février 2015 - art. 1 (V)	8 years ago
 Titre préliminaire	Créé par LOI n°2013-404 du 17 mai 2013 - art. 13	10 years ago
 README.md	Improve README	8 years ago

 **README.md**

Le Code civil français, sous Git

« Nul n'est censé ignorer la loi. »

Et pourtant nous autres citoyens (moi y compris) ne connaissons pas les lois qui construisent et gouvernent notre République. Pour faire passer nos idées, nos textes sont bien connus et commentés.

About

Le code civil français sous git

 Readme

 2.7k stars

 217 watching

 149 forks

Releases

No releases published

Packages

No packages published

Contributors

 3

-  **steeve** Steeve Morin
-  **emerick42** Emerick Kasbarian
-  **Kcchouette**

Projet "france.code-civil" : <https://github.com/steeve/france.code-civil>

Gestion de projet avec GitHub - historique d'un projet

steeve / france.code-civil Public

<> Code Issues 21 Pull requests 9 Actions Projects Wiki Security

master

Commits on Mar 31, 2015

Merge pull request #18 from Kcchouette/patch-1 ... 2 159d051 <>

steeve committed on 31 Mar 2015

Improve README ... 1 d069119 <>


Kcchouette committed on 31 Mar 2015

"Nul n'est censé ignorer la loi." ... 1 Unverified 0fe3371 <>

steeve committed on 31 Mar 2015

Projet "france.code-civil" : <https://github.com/steeve/france.code-civil>

Gestion de projet avec GitHub - communiquer



The screenshot shows the GitHub interface for the repository 'steeve / france.code-civil', which is marked as 'Public'. The navigation bar includes links for 'Code', 'Issues' (which is selected and underlined), and 'Pull requests'. Below the navigation bar is a search bar containing the text 'is:issue is:open'. The main content area displays a summary of 21 open issues and 10 closed issues. Below this summary, four specific issues are listed, each with a green circular icon containing a white dot. The issues are: 'Code source du projet' (opened 23 May 2017 by vladimirkosmala), 'Est-ce que ce repo est toujours à jour ?' (opened 28 Sep 2016 by JeSuisUnCaillou), '"Nul n'est censé ignorer la loi."' (opened 4 May 2015 by tux-00), and 'Tous les codes' (opened 9 Apr 2015 by steeve).

steeve / france.code-civil Public

<> Code Issues 21 Pull requests 9

Q is:issue is:open

21 Open ✓ 10 Closed

- Code source du projet
#46 opened on 23 May 2017 by vladimirkosmala
- Est-ce que ce repo est toujours à jour ?
#45 opened on 28 Sep 2016 by JeSuisUnCaillou
- "Nul n'est censé ignorer la loi."
#41 opened on 4 May 2015 by tux-00
- Tous les codes
#39 opened on 9 Apr 2015 by steeve


Projet "france.code-civil" : <https://github.com/steeve/france.code-civil>

Page web avec GitHub

 **Engineering** [Home](#) [Blog](#) [Open Source](#) [AWE](#) [What's it like?](#)

Yelp Open Source

- Power your app with the same code Yelp uses every day
- We love open source and want to give back with projects like mrjob
- Get started today with 99 projects from 66 Yelp developers



Popular



paasta

★ 1619 ▼ 222 **Python**

An open, distributed platform as a service

[Blog post](#)

```
16 query_key: username
17 timeframe:
18 days: 1
19 filter:
20 - query:
21   query_string:
22     query: "document_ty
```

elastalert

★ 7830 ▼ 1771 **Python**

Easy & Flexible Alerting With Elasticsearch

[Blog post](#)



undebt

★ 1638 ▼ 62 **Python**

A fast, straightforward, reliable tool for performing massive, automated code refactoring

[Blog post](#)

```
root@and27f68dc8:/code$ ps auxf
PID  STAT  TIME  COMMAND
1  ss    0:00  dumb_init
7  ss    0:00  runsvdir
8  S      0:00  \ runsv
9  S      0:00  \ logger
10 S     0:15  \ python3
14 -S    0:28  \ net
```

dumb-init

★ 5861 ▼ 322 **Python**

A minimal init system for Linux containers

[Blog post](#)

Page GitHub des projets *open source* de Yelp : <https://yelp.github.io>

Organiser son travail

 YoannDupont Better counting of entities in corpus. 0fe35f0 on 23 Jul 2019  8 commits		
	2016	Adding political affairs as events. 4 years ago
	2017	Adding political affairs as events. 4 years ago
	2018	Adding political affairs as events. 4 years ago
	.gitignore	Initial commit 4 years ago
	changelog.md	corrections on products such as Wikipedia or Twitter. 4 years ago
	concatenate_dir.py	corrections on products such as Wikipedia or Twitter. 4 years ago
	concatenate_subdirs.py	corrections on products such as Wikipedia or Twitter. 4 years ago
	count.py	Better counting of entities in corpus. 3 years ago
	get_inconsistencies.py	Wikinews 2018 annotated. 4 years ago
	get_month_articles.py	Wikinews 2018 annotated. 4 years ago
	license.txt	Added the Wikinews 2016, 2017 and the first three months of 2018 doc... 4 years ago
	make_matches.py	Wikinews 2018 annotated. 4 years ago
	readme.md	Added: 4 years ago

Source : WiNER-fr <https://github.com/YoannDupont/WiNER-fr>

Organiser son travail

```
├─ year
│   ├── month1
│   │   ├── *.ann
│   │   └── *.txt
│   ├── month2
│   │   ├── *.ann
│   │   └── *.txt
│   ├── year-month1-urls.txt
│   └── year-month2-urls.txt
```

Source : WiNER-fr <https://github.com/YoannDupont/WiNER-fr>

Instant démonstration

Et maintenant la pratique

On prépare ses moyens de travailler

- Inscrivez-vous sur GitHub
 - Demandera peut-être l'installation d'une app pour créer des codes temporaires (ex: authy)
- Remplissez le framacalc avec vos mail et compte github : <retiré pour diffusion>
- Créez un dépôt bidon qui servira à faire des manipulations, on appellera le nôtre "git-along".

Créer une clé de sécurité pour GitHub

On va simplement créer cette clé pour vous permettre d'utiliser GitHub. On expliquera plus en détail la semaine prochaine.

```
ssh-keygen -t ed25519
```

source : <https://docs.github.com/en/authentication/connecting-to-github-with-ssh/generating-a-new-ssh-key-and-adding-it-to-the-ssh-agent>

Créer une clé de sécurité pour GitHub

On va simplement créer cette clé pour vous permettre d'utiliser GitHub. On expliquera plus en détail la semaine prochaine.

```
ssh-keygen -t ed25519
```

La commande vous demandera alors :

1. Où sauvegarder la clé (par défaut la clé privée dans `~/.ssh/id_ed25519` et la publique dans `~/.ssh/id_ed25519.pub`)
2. Un mot de passe pour la clé (qu'il faudra entrer à chaque fois)
 - 2.1 On peut ne rien donner, mais pas recommandé

source : <https://docs.github.com/en/authentication/connecting-to-github-with-ssh/generating-a-new-ssh-key-and-adding-it-to-the-ssh-agent>

Troubleshooting "*permissions are too open*"

Si vous avez un message de type "*permissions are too open*", il faudra changer certains droits de vos fichiers de manière appropriée :

```

@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@
@          WARNING: UNPROTECTED PRIVATE KEY FILE!          @
@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@@
Permissions 0750 for ' [REDACTED] ' are too open.
It is required that your private key files are NOT accessible by others.
This private key will be ignored.

```

Figure 3: Le message que vous avez peut-être vu.

Ajouter la clé à votre agent SSH

Vérifier que votre agent SSH tourne :

```
eval "$(ssh-agent -s)"
```

source : <https://docs.github.com/en/authentication/connecting-to-github-with-ssh/generating-a-new-ssh-key-and-adding-it-to-the-ssh-agent>

Ajouter la clé à votre agent SSH

Vérifier que votre agent SSH tourne :

```
eval "$(ssh-agent -s)"
```


Affichera un message type "Agent pid XXXX". Si tel est le cas, on ajoute la clé à l'agent (en supposant que ~/.ssh/id_ed25519 est votre clé privée) :

```
ssh-add $HOME/.ssh/id_ed25519
```

source : <https://docs.github.com/en/authentication/connecting-to-github-with-ssh/generating-a-new-ssh-key-and-adding-it-to-the-ssh-agent>

Ajouter la clé à GitHub

Finalement, on ajoute la clé **publique** (termine par .pub) à GitHub via les *settings*.



The screenshot shows the GitHub settings interface for a user named YoannDupont. On the left is a sidebar with navigation links: Public profile, Account, Appearance, Accessibility, Notifications, Access, Billing and plans, Emails, Password and authentication, SSH and GPG keys (highlighted), Organizations, and Moderation. The main content area is titled 'SSH keys' and includes a 'New SSH key' button. Below the title is a description: 'This is a list of SSH keys associated with your account. Remove any keys that you do not recognize.' Underneath, the 'Authentication Keys' section displays a table with two rows, each representing an SSH key. The key names are redacted with a black box, and each row has a 'Delete' button. At the bottom of the main area, there is a link to a guide on generating SSH keys and troubleshooting common problems.

YoannDupont
Your personal account

- Public profile
- Account
- Appearance
- Accessibility
- Notifications

Access

- Billing and plans
- Emails
- Password and authentication
- SSH and GPG keys**
- Organizations
- Moderation

SSH keys

New SSH key

This is a list of SSH keys associated with your account. Remove any keys that you do not recognize.

Authentication Keys

 SSH	[Redacted]	Delete
 SSH	[Redacted]	Delete

Check out our guide to [generating SSH keys](#) or troubleshoot [common SSH problems](#).

source : <https://docs.github.com/en/authentication/connecting-to-github-with-ssh/adding-a-new-ssh-key-to-your-github-account>

Récupérer le git du cours et le mettre à jour

Premier exemple pour récupérer un dépôt en ligne, celui du cours :

<https://github.com/YoannDupont/PPE1-2627>

```
git clone git@github.com:YoannDupont/PPE1-2627.git
```

Va créer le dossier PPE1-2627.

Puis pour le mettre à jour, on va dans le dossier PPE1-2627 et on le met à jour :

```
cd PPE1-2627  
git pull
```

Et voilà, tout le monde peut être à jour comme ça.

On va maintenant créer un dossier git "bidon" qui servira à faire des manipulations de test, on va appeler ce dépôt "git-along".

Démo synchronisée de création du dépôt.




Figure 4: Une fois connecté-e sur <https://github.com>, en haut à droite, cliquez sur "+" puis "new repository".

Créer un dépôt GitHub II

- **Repository Name** : PPE1
(uniquement PPE1)
- **Description** : Programmation et
Projet Encadré 1
- **Public** : cocher
- **Add a README file** : cocher
- **Add a .gitignore** : pas nécessaire
ici
- **Licence** : comme vous voulez
- cliquez sur "create repository"

1 General

Owner *



YoannDupont

Repository name *

PPE1-2025

✓ PPE1-2025 is available.

Great repository names are short and memorable. How about [shiny-octo-rob](#)?

Description

Dépôt individuel de PPE pour l'année 2025-2026.

47 / 350 characters

2 Configuration

Choose visibility *

Choose who can see and commit to this repository

Add README

READMEs can be used as longer descriptions. [About READMEs](#)

Add .gitignore

.gitignore tells git which files not to track. [About ignoring files](#)

Add license

Licenses explain how others can use your code. [About licenses](#)